数据集分析报告

数据集：wine_sample.csv

1. 数据集概览

数据行数	1596
字段数	12
完全重复行	239
去重后行数	1357
内存占用	0.15 MB

下列统计均基于未去重的原始数据；去重后的行数见上表。

2. 字段与类型

字段	类型	非空值	缺失值	唯一值
固定酸度	float64	1596	0	96
挥发性酸度	float64	1595	1	143
柠檬酸	float64	1595	1	80
残糖	float64	1595	1	91
氯化物	float64	1596	0	153
游离二氧化硫	float64	1594	2	60
总二氧化硫	float64	1596	0	144
密度	float64	1596	0	436
PH值	float64	1595	1	89
硫酸盐	float64	1596	0	96
酒精	float64	1596	0	65
质量评分	int64	1596	0	6

3. 缺失值分析

字段	缺失数	缺失占比
游离二氧化硫	2	0.13%
挥发性酸度	1	0.06%
柠檬酸	1	0.06%
残糖	1	0.06%
PH值	1	0.06%

4. 重复行检查

检测到 239 行完全重复数据，占总行数的 14.97%；去重后剩余 1357 行。建议确认是否为重复录入，并说明后续分析采用哪种口径。

5. 数值字段统计

index	count	mean	std	min	25%
固定酸度	1596	8.321	1.7424	4.6	7.1
挥发性酸度	1595	0.5277	0.1792	0.12	0.39
柠檬酸	1595	0.2713	0.1948	0	0.09
残糖	1595	2.54	1.4113	0.9	1.9
氯化物	1596	0.0875	0.0471	0.012	0.07
游离二氧化硫	1594	15.8846	10.4735	1	7
总二氧化硫	1596	46.5	32.9153	6	22
密度	1596	0.9967	0.0019	0.9901	0.9956
PH值	1595	3.3111	0.1545	2.74	3.21
硫酸盐	1596	0.6581	0.1695	0.33	0.55
酒精	1596	10.4246	1.066	8.4	9.5
质量评分	1596	5.6366	0.808	3	5

6. 类别与离散字段分布

字段	高频取值（前 5）	唯一值数
质量评分	5(679)，6(637)，7(199)，4(53)，8(18)	6

其中唯一值较少的数值列（如评分、等级）按离散分布处理。

7. 数值字段相关性

字段	固定酸度	挥发性酸度	柠檬酸	密度	PH值	硫酸盐	酒精	质量评分
固定酸度	1	-0.256	0.672	0.668	-0.683	0.183	-0.062	0.124
挥发性酸度	-0.256	1	-0.552	0.022	0.234	-0.26	-0.202	-0.391
柠檬酸	0.672	-0.552	1	0.365	-0.542	0.313	0.109	0.226
密度	0.668	0.022	0.365	1	-0.342	0.149	-0.496	-0.175
PH值	-0.683	0.234	-0.542	-0.342	1	-0.196	0.206	-0.058
硫酸盐	0.183	-0.26	0.313	0.149	-0.196	1	0.094	0.252
酒精	-0.062	-0.202	0.109	-0.496	0.206	0.094	1	0.476
质量评分	0.124	-0.391	0.226	-0.175	-0.058	0.252	0.476	1

受版面限制未显示：残糖、氯化物、游离二氧化硫、总二氧化硫。这些字段与其他字段的相关系数可在对话的分析结果里查看。

8. 数据质量与建议

重复行：239 行完全重复（占 14.97%），去重后 1357 行。分析前应明确是否去重，否则统计量会被重复样本放大。

强偏态字段：残糖（中位数 2.2，均值 2.54）、氯化物（中位数 0.079，均值 0.08746）、硫酸盐（中位数 0.62，均值 0.6581）。偏度大于 2，均值容易被极值拉偏，描述这类字段时应同时给中位数。

9. 数据样例（前 10 行，前 8 列）

固定酸度	挥发性酸度	柠檬酸	残糖	氯化物	游离二氧化硫	总二氧化硫	密度
7.4	0.7	0	1.9	0.076	11	34	0.9978
7.8	0.88	0	2.6	0.098	25	67	0.9968
7.8	0.76	0.04	2.3	0.092	15	54	0.997
11.2	0.28	0.56	1.9	0.075	17	60	0.998
7.4	0.7	0	1.9	0.076	11	34	0.9978
7.4	0.66	0	1.8	0.075	13	40	0.9978
7.9	0.6	0.06	1.6	0.069	15	59	0.9964
7.3	0.65	0	1.2	0.065	15	21	0.9946
7.8	0.58	0.02	2	0.073	9	18	0.9968
7.5	0.5	0.36	6.1	0.071	17	102	0.9978

另有 4 列未显示：PH值、硫酸盐、酒精、质量评分。

分析结果

以下为本次会话中基于该数据集完成的问答与分析。

1. 每个质量评分对应的平均酒精含量是多少？

各质量评分的平均酒精含量

质量评分	平均酒精含量	样本数
3	9.955	10
4	10.265	53
5	9.901	679
6	10.631	637
7	11.466	199
8	12.094	18

整体来看，质量评分越高，平均酒精含量也越高：评分 5 到 8 之间，平均酒精含量从 9.901 稳步上升到 12.094。评分 3 和 4 的样本量很小（分别为 10 和 53），因此它们的均值波动较大，参考价值有限；评分 5 和 6 的样本量最大（分别为 679 和 637），结果最稳定。

需要注意，这只是分组均值对比，说明酒精含量与质量评分之间存在同向关联，但并不代表因果关系。

结果表：

质量评分	平均酒精含量	样本数
3	9.955	10
4	10.2651	53
5	9.901	679
6	10.6308	637
7	11.4659	199
8	12.0944	18

2. 哪些理化指标跟质量评分关系最强？按相关系数排序

各理化指标与质量评分的相关系数（按绝对值降序）

指标	相关系数	绝对值
酒精	0.4759	0.4759
挥发性酸度	-0.3909	0.3909
硫酸盐	0.2523	0.2523
柠檬酸	0.2264	0.2264
总二氧化硫	-0.1853	0.1853
密度	-0.1749	0.1749
氯化物	-0.1288	0.1288
固定酸度	0.1238	0.1238
PH值	-0.0580	0.0580
游离二氧化硫	-0.0509	0.0509
残糖	0.0134	0.0134

要点

- 酒精与质量评分正相关最强（0.476），是这批指标中关联最明显的。
- 挥发性酸度呈明显负相关（-0.391），即挥发性酸度越高，评分倾向越低。
- 硫酸盐（0.252）与柠檬酸（0.226）为中等偏弱的正相关。
- 总二氧化硫（-0.185）、密度（-0.175）、氯化物（-0.129）、固定酸度（0.124）关联较弱。
- PH值（-0.058）、游离二氧化硫（-0.051）、残糖（0.013）几乎与评分无线性关联。

需要注意：以上均为线性相关系数，只能反映线性关联的强弱与方向，相关不等于因果；数值普遍不高，说明单一指标对评分的解释力有限，评分更可能由多个指标共同作用。

结果表：

相关系数	绝对值
0.4759	0.4759
-0.3909	0.3909
0.2523	0.2523
0.2264	0.2264
-0.1853	0.1853
-0.1749	0.1749
-0.1288	0.1288
0.1238	0.1238
-0.058	0.058
-0.0509	0.0509

（仅显示前 10 行、前 8 列；完整结果共 11 行 × 2 列）

3. 评分 ≥7 和 ≤5 的酒，在酒精、挥发性酸度、总二氧化硫上差多少？

分组均值对比

指标	高分组（≥7，n=217）	低分组（≤5，n=742）	差值（高－低）
酒精	11.518	9.928	+1.590
挥发性酸度	0.406	0.590	－0.184
总二氧化硫	34.889	54.695	－19.806

解读

- 酒精：高分组平均比低分组高约 1.59，是三项中唯一高分组更高的指标。
- 挥发性酸度：高分组平均低约 0.18，低分组明显偏高。

- 总二氧化硫：高分组平均低约 19.8，差距在比例上最为突出（低分组约为高分组的 1.57 倍）。
- 样本量：高分组 217 条，低分组 742 条，低分组约为高分组的 3.4 倍，两组规模不均衡。

以上均为组间均值差异，仅反映数据中的关联，不代表因果关系。

结果表：

高分组均值	低分组均值	差值(高-低)
11.518	9.9278	1.5903
0.4055	0.5896	-0.184
34.8894	54.6954	-19.806
217	742	-525

4. 画一张各质量评分样本数的柱状图

各质量评分样本数

质量评分	样本数
3	10
4	53
5	679
6	637
7	199
8	18
合计	1596

分布高度集中：评分 5 和 6 合计 1316 个样本，占全部 1596 个样本的绝大多数；两端（3 分 10 个、8 分 18 个）样本很少，属于明显的不平衡分布。柱状图已按评分从低到高绘制，并在每根柱子上标注了对应样本数。

补充说明：数据集中存在 239
行完全重复记录，上述计数包含这些重复行；若去重后统计，各评分的样本数会相应减少。

结果表：

count
10
53
679
637
199
18

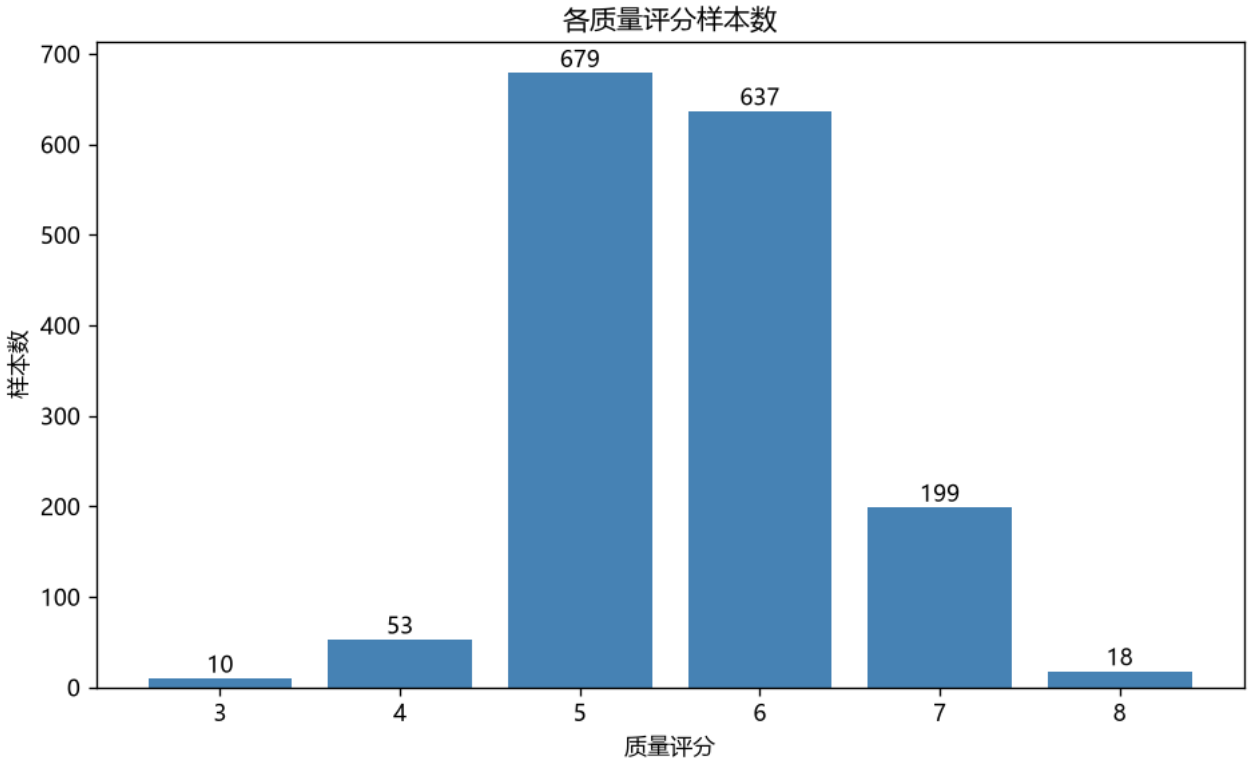
各质量评分样本数
样本数
质量评分
0
100
200
300
400
500
600
700
3
4
5
6
7
8
10
53
679
637
199
18